



中山大學  
SUN YAT-SEN UNIVERSITY



国家超级计算广州中心  
NATIONAL SUPERCOMPUTER CENTER IN GUANGZHOU

# Compilation Principle 编译原理

---

## 第0讲：课程介绍、概述

张献伟

[xianweiz.github.io](https://xianweiz.github.io)

DCS290, Spring 2021



中山大學  
SUN YAT-SEN UNIVERSITY



# 任课教师



博士，2011 – 2017，University of Pittsburgh



学士，2007 – 2011，西北工业大学

中山大学


副教授，2020.10 – 今




工程师/研究员，2017.08 – 2020.09



实习研究员，2016.05 – 2016.08



计算机体系结构  
高性能及智能计算  
软硬件设计及优化



学院个人主页: <http://sdcs.sysu.edu.cn/content/5592>

# 课时安排

---

- 编译原理（3学分，54学时）
  - 排课：1-19周
    - 周二：2-9，11-19周
    - 周四：1-9，11-19周
  - 每次授课包括2个课时
    - 第五节：14:20 – 15:05，第六节：15:15 – 16:00
  - 地点：教学大楼 C303
- 编译器构造实验（1学分，36学时）
  - 排课：1-19周
    - 周四：1-9，11-19周
  - 每次授课包括2个课时
    - 第七节：16:20 – 17:05，第八节：17:15 – 18:00
  - 地点：实验中心 E401

# 考核要求

---

- 编译原理

- 课堂参与（10%）- 点名、提问、测试
- 课程作业（20%）- 4次左右，理论
- 期中考查（10%）- 课下习题
- 期末考试（60%）- 闭卷

- 编译器构造实验

- Project 1（25%）- Lexical Analysis
- Project 2（25%）- Syntax Analysis
- Project 3（25%）- Semantic Analysis
- Project 4（25%）- Code Generation

- 课堂

- 随机点名
  - 缺席优先
- 随机提问
  - 后排优先
- 随机测试

- 实验

- 个人完成
  - 杜绝抄袭
- 按时提交
  - 硬性截止
- 侧重代码实现
  - 无需报告

# 课件及答疑

---

- 课件

- [xianweiz.github.io/teach/dcs290/s2021.html](http://xianweiz.github.io/teach/dcs290/s2021.html)
  - 课后上传更新

- 教师

- 张献伟（超算中心）
    - Email: [zhangxw79@mail.sysu.edu.cn](mailto:zhangxw79@mail.sysu.edu.cn)
    - 实验课答疑，其他时间需预约

- 助教

- 理论：莫泽威
    - Email: [mozw5@mail2.sysu.edu.cn](mailto:mozw5@mail2.sysu.edu.cn)
    - 研究方向：GCC/LLVM优化
  - 实验：王子彦
    - Email: [wangzy75@mail2.sysu.edu.cn](mailto:wangzy75@mail2.sysu.edu.cn)
    - 研究方向：区块链编译优化

# 关于课程

---

- 年级专业
  - 18级计科（专必，38人）
  - 18级保密管理（专选，9人）
- 先修课程
  - 计算机体系结构/组成原理、汇编语言
  - 离散数学、数据结构、C/C++或其他编程语言
- 编译原理
  - 高级编程语言（如C）是如何转换为机器语言（0/1）的？
  - 介绍编译器设计与实现的主要理论和技术
    - 包括词法分析、语法分析、语义分析、代码生成、代码优化等
- 编译器构造实验
  - 单独课程，分阶段实现一个小型编译器
    - 词法分析、语法分析、语义分析等

# 课程教材


- 主要教材

- 编译原理（Compilers: Principles, Techniques, and Tools, 2<sup>nd</sup> Edition）, By Alfred V. Aho, Monica S. Lam, and *et al.*



- 参考资料

- Computer Systems: A Programmer's Perspective (CSAPP), Bryant and O'Hallaron
- 编译原理，陈鄞（哈工大）
- 编译原理，王挺（国防科大）
- COMS 4115, Baishakhi Ray (Columbia U.)
- CS 143, Fredrik Kjolstad (Stanford U.)
- CS 411, Jan Hoffmann (Carnegie Mellon U.)
- CS 2210, Wonsun Ahn (U. of Pittsburgh)



# 教学安排

周次	课程内容	周次	课程内容
第1周 (02.25)	四：课程介绍、编译概述	第11周 (05.06)	四：中间代码 – IR表示
第2周 (03.02/04)	二：词法分析 – 过程、正则表达 四：词法分析 – NFA、DFA (1)	第12周 (05.13)	四：中间代码 – 生成
第3周 (03.09/11)	二：词法分析 – NFA、DFA (2) 四：语法分析 – 语法、语言、CFG	第13周 (05.20)	四：运行时管理
第4周 (03.16/18)	二：语法分析 – 自顶向下、文法 (1) 四：语法分析 – 自顶向下、文法 (2)	第14周 (05.27)	四：运行时代码生成
第5周 (03.23/25)	二：语法分析 – 自底向上、LR分析 (1) 四：语法分析 – 自底向上、LR分析 (2)	第15周 (06.03)	四：代码优化
第6周 (03.30/04.01)	二：语法分析 – 更多LR分析 四：语法分析 – YACC工具	第16周 (06.10)	四：控制流、数据流分析
第7周 (04.06/08)	二：语义分析 – 符号表 四：语义分析 – 类型检查	第17周 (06.17)	四：目标代码生成
第8周 (04.13/15)	二：语法制导翻译 (1) 四：语法制导翻译 (2)	第18周 (06.24)	四：前沿编译技术
第9周 (04.20/22)	二：回顾 – 编译前端 四：介绍 – 编译后端	第19周 (07.01)	四：总结 – 编译前后端
第10周	(期中：课下考查)	第20周	(期末：闭卷考试)



# 编译器的发展

---

- Compiler History
  - 1952: A-0, term ‘compiler’ (Grace Hopper)
  - 1957: FORTRAN, first commercial compiler (John Backus)
  - 1962: LISP, self-hosting and GC (Tim Hart and Mike Levin)
  - 1984: GNU Compiler Collection (Stallman)
- Turing Awards (see [link](#))
  - Compiler: 1966, 1987, 2006
  - Programming Language: 1972, 1974, 1977-1981, 1984, 2001, 2003, 2005, 2008
- Compilers Today
  - Modern compilers are complex (gcc has 7M+ LOC)
  - There is still a lot of compiler research (LLVM, ...)
  - There is still a lot of compiler development in industry


# 为什么要学习编译？

---

- 计算机生态一直在改变
  - 新的硬件架构（通用GPU、AI加速器等）
  - 新的程序语言（Rust、Go等）
  - 新的应用场景（DL、IoT等）
- 了解编译程序的实现原理与技术
  - 掌握编译程序/系统设计的基本原理
  - 理解高级语言程序的内部运行机制
    - 提高编写和调试程序的能力
  - 培养形式化描述和抽象思维能力
- 大量专业工作与编译技术相关
  - 高级语言实现、软硬件设计与优化、软件缺陷分析
- 硕博士阶段从事与编译相关的研究
  - 尽管可能并不是直接的编译或程序设计方向

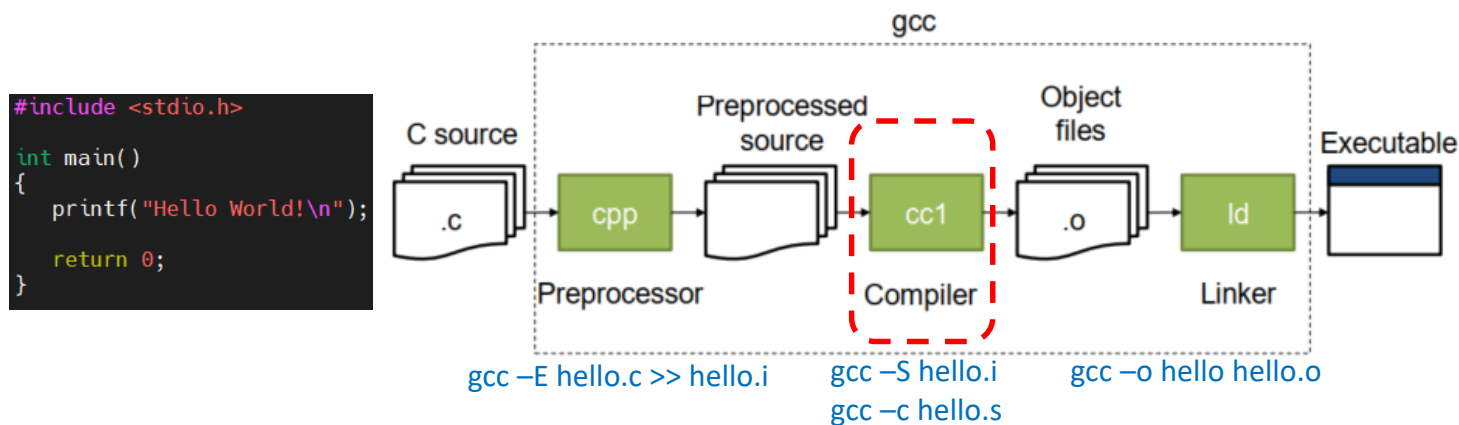
# 什么是编译？

- 高级语言编写程序，但计算机只理解0/1
  - 自然语言翻译：“This is a sentence” → “这是一个句子”
  - 计算机语言翻译：源程序 → 目标程序
  - 编程人员专注于程序设计，无需过多考虑机器相关的细节
- 不同语言有不同的实现方式
  - “底层”语言通常使用编译
    - C, C++
  - “高级”语言通常是解释性的
    - Python, Ruby
  - 有些使用混合的方式
    - Java：编译 + 即时编译（JIT, Just-in-Time）



# C语言编译

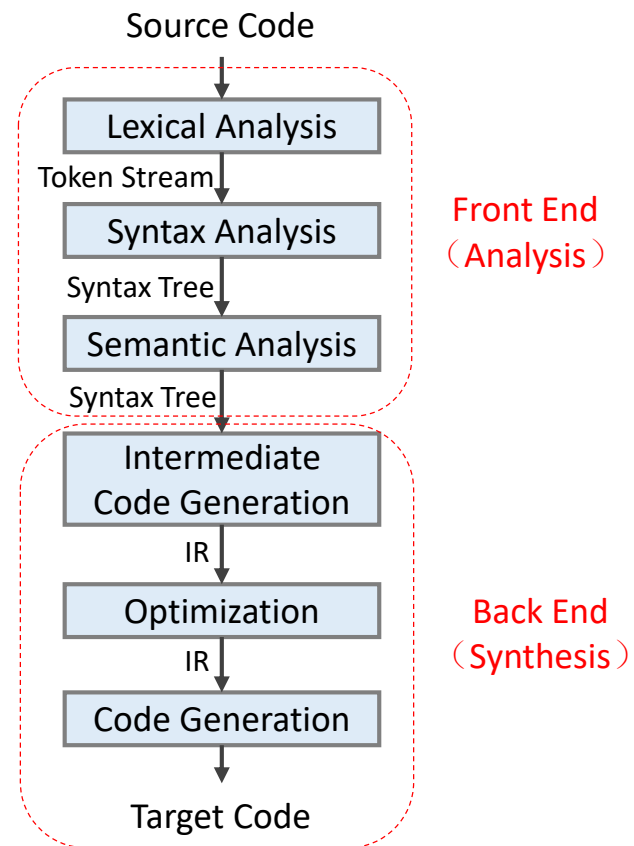
- 源程序 (hello.c) → 可执行文件(./hello)
  - 预处理阶段 (preprocessor)
    - 汇合源程序，展开宏定义，生成.i文件（另一个C文本文件）
  - 编译阶段 (compiler)
    - .i文件翻译为.s文件（汇编代码）
  - 汇编阶段 (assembler)
    - .s文件转为.o可重定位对象（relocatable object）文件（机器指令）
  - 连接阶段 (linker/loader)
    - 连接库代码从而生成可执行（executable）文件（机器指令）



```
55
48 89 e5
bf d0 05 40 00
e8 d5 fe ff ff
b8 00 00 00 00
5d
c3
```

# 编译过程

- **前端（分析）**：对源程序，识别语法结构信息，理解语义信息，反馈出错信息
  - 词法分析（Lexical Analysis）
  - 语法分析（Syntax Analysis）
  - 语义分析（Semantic Analysis）
- **后端（综合）**：综合分析结果，生成语义上等价于源程序的目标程序
  - 中间代码生成（Intermediate Code Generation）
    - Intermediate representation (IR)
  - 代码优化（Code Optimization）
  - 目标代码生成（Code Generation）



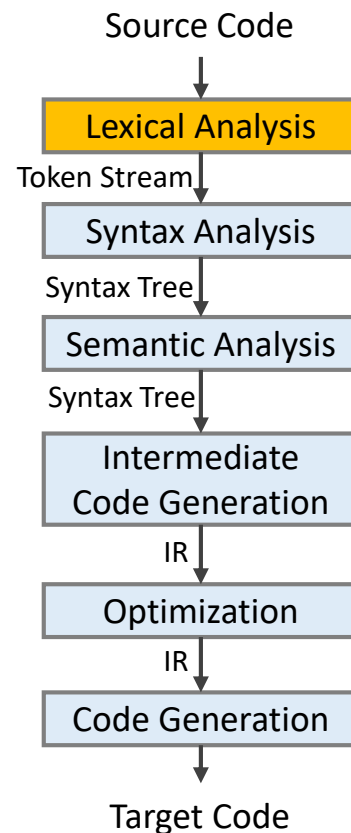
# 词法分析

- 扫描源程序字符流，识别并分解出有词法意义的单词或符号（**token**）

- 输入：源程序, 输出：token序列
- token表示：<类别, 属性值>
  - 保留字、标示符、常量、运算符等
- token是否符合词法规则?
  - Ovar, \$num

```
void main()  
{  
    int arr[10], i, x = 1;  
    for (i = 0; i < 10; i++)  
        arr[i] = x * 5;  
}
```

keyword(for) id(i) sym(=) num(0) sym(;) id(i) sym(<) num(10) sym(;) id(i) sym(++)  
id(arr) sym([) id(i) sym(]) sym(=) id(x) sym(\*) num(5) symbol(;



# 语法分析

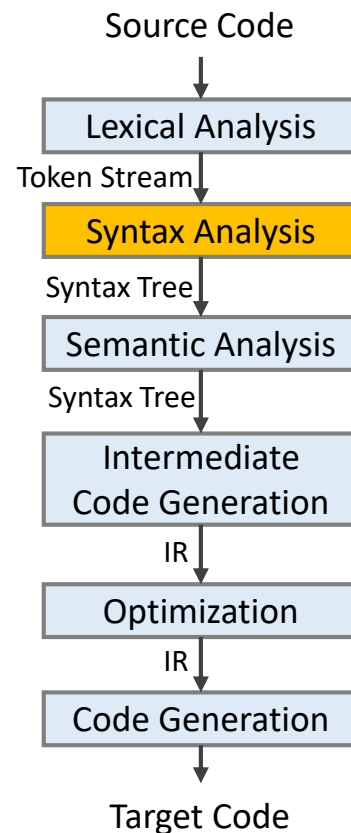

- 解析源程序对应的token序列，生成语法分析结构（语法分析树）

- 输入：单词流，输出：语法树
- 输入程序是否符合语法规则？

□  $x^*+$

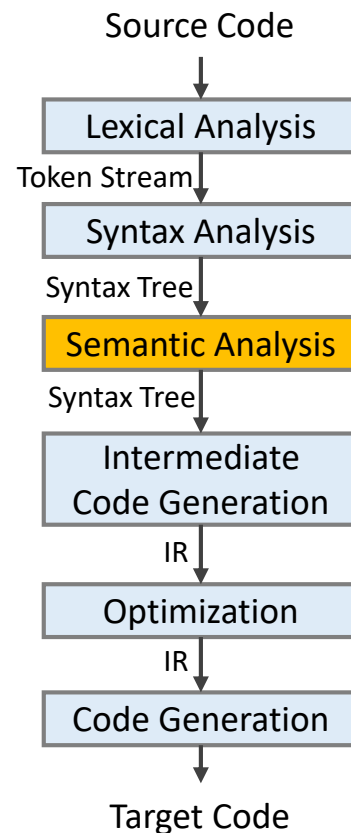
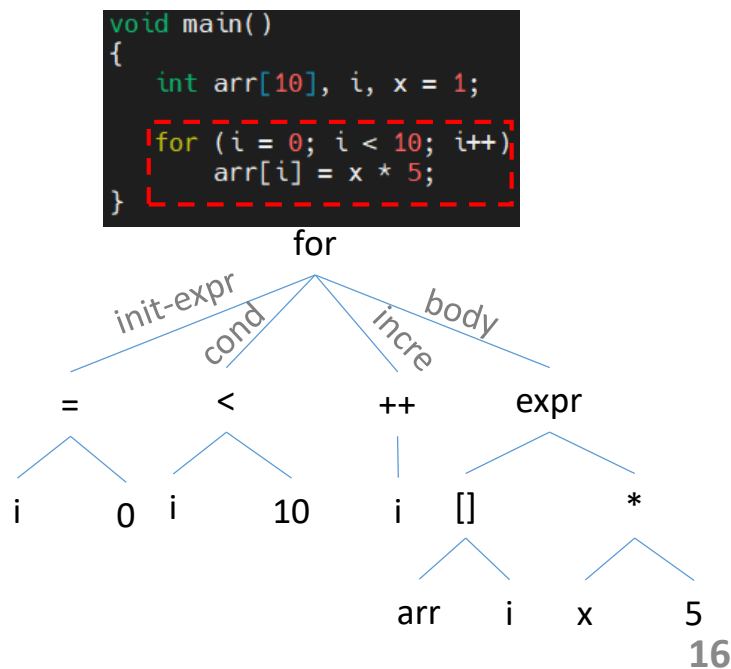
□  $a += 5;$

```
void main()  
{  
    int arr[10], i, x = 1;  
    for (i = 0; i < 10; i++)  
        arr[i] = x * 5;  
}
```



# 语义分析

- 基于语法结果进一步分析语义
  - 输入：语法树，输出：语法树+符号表
  - 收集标识符的属性信息（**type**, **scope**等）
  - 输入程序是否符合语义规则?
    - 变量未声明即使用，重复声明
    - `int x; y = x(3);`



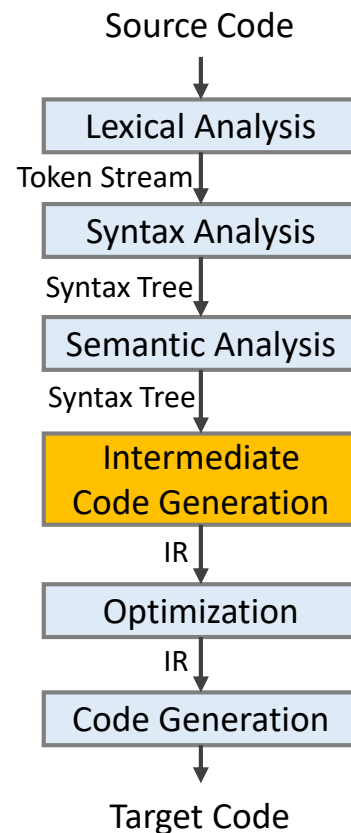


# 中间代码生成

- 初步翻译，生成等价于源程序的中间表示（IR）
  - 输入：语法树，输出：IR
  - 建立源和目标语言的桥梁，易于翻译过程的实现，利于实现某些优化算法
  - IR形式：例如三地址码（TAC, Three-Address Code）

```
void main()  
{  
    int arr[10], i, x = 1;  
    for (i = 0; i < 10; i++)  
        arr[i] = x * 5;  
}
```

```
i := 0  
loop:  
    t1 := x * 5  
    t2 := &arr  
    t3 := sizeof(int)  
    t4 := t3 * i  
    t5 := t2 + t4  
    *t5 := t1  
    i := i + 1  
    if i < 10 goto loop
```

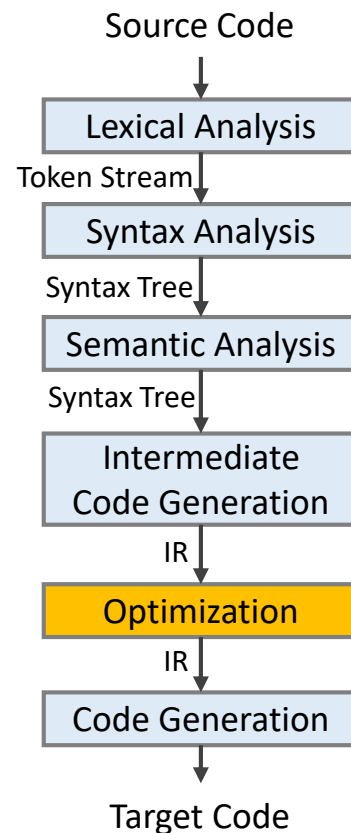


# 代码优化

- 加工变换中间代码使其更好（代码更短、性能更高、内存使用更少）
  - 输入：IR，输出：（优化的）IR
  - 机器无关（machine independent）
  - 例如：设别重复运算并删除；运算操作替换；使用已知量

```
void main()  
{  
    int arr[10], i, x = 1;  
    for (i = 0; i < 10; i++)  
        arr[i] = x * 5;  
}
```

```
i := 0  
loop:  
    t1 := x * 5  
    t2 := &arr  
    t3 := sizeof(int)  
    t4 := t3 * i  
    t5 := t2 + t4  
    *t5 := t1  
    i := i + 1  
    if i < 10 goto loop
```

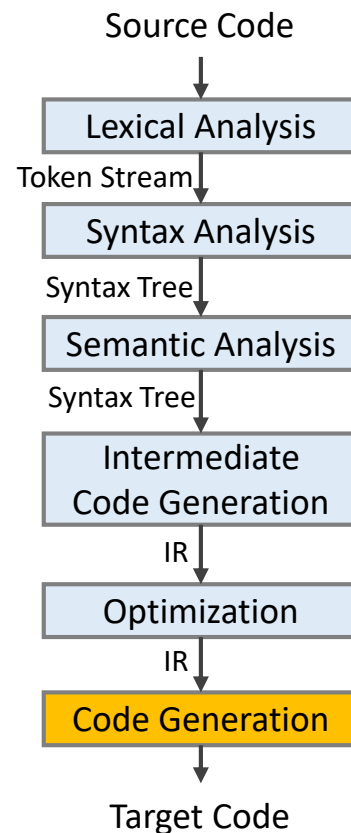


# 目标代码生成

- 为特定机器产生目标代码（e.g., 汇编）
  - 输入：（优化的）IR，输出：目标代码
  - 寄存器分配：放置频繁访问数据
  - 指令选取：确定机器指令实现IR操作
  - 进一步的机器有关优化
    - 例如：寄存器及访存优化

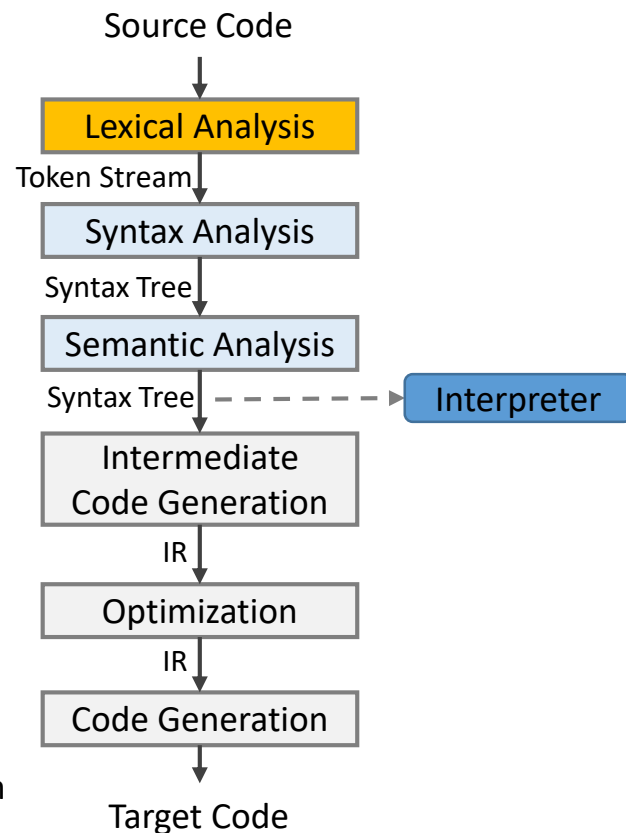
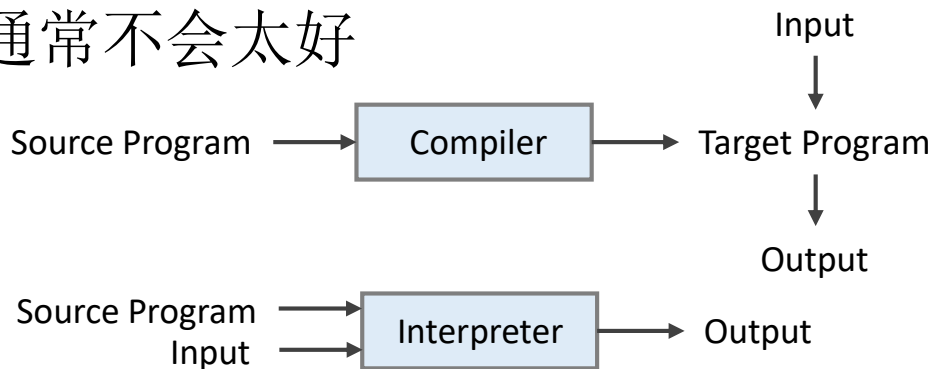
```
void main()  
{  
    int arr[10], i, x = 1;  
    for (i = 0; i < 10; i++)  
        arr[i] = x * 5;  
}
```

14: 8b 55 f8	mov	-0x8(%rbp),%edx	// edx = x
17: 89 d0	mov	%edx,%eax	// eax = x
19: c1 e0 02	shl	\$0x2,%eax	// eax = (x << 2)
1c: 01 c2	add	%eax,%edx	// edx = (x << 2) + x
1e: 8b 45 fc	mov	-0x4(%rbp),%eax	// eax = i
21: 48 98	cltq		
23: 89 54 85 d0	mov	%edx,-0x30(%rbp,%rax,4)	// arr[i] = 5x
27: 83 45 fc 01	addl	\$0x1,-0x4(%rbp)	// i++
2b: 83 7d fc 09	cmpl	\$0x9,-0x4(%rbp)	// i <= 9
2f: 7e e3	jle	14 <main+0x14>	// loop end?



# 解释 vs. 编译

- 编译：翻译成机器语言后方能运行
  - 目标程序独立于源程序（修改 → 再编译 → 运行）
  - 分析程序上下文，易于整体性优化
  - 性能更好（核心代码通常C/C++）
- 解释：源程序作为输入，边解释边执行
  - 不生成目标程序，可迁移性高
  - 逐句执行，很难进行优化
  - 性能通常不会太好



# 即时编译 (JIT)

- 即时编译 (Just-In-Time Compiler) :  
运行时执行程序编译操作
  - 弥补解释执行的不足
    - 把翻译过的机器代码保存起来, 以备下次使用
  - 传统编译 (AOT, Ahead-Of-Time) : 先编译后运行
- JIT vs. AOT
  - JIT具备解释器的灵活性
    - 只要有JIT编译器, 代码即可运行
  - 性能上基本和AOT等同
    - 运行时编译操作带来一些性能上的损失
    - 但可以利用程序运行特征进行动态优化

